



UNIVERSITÀ POLITECNICA DELLE  
MARCHE

DIGITAL ADAPTIVE CIRCUITS AND LEARNING  
SYSTEMS

# Sound Event Detection con la tecnica del “*few-shot learning*”

*Matteo Orlandini e Jacopo Pagliuca*

Prof. Stefano SQUARTINI  
Dott.ssa Michela CANTARINI

16 luglio 2021

# Indice

<b>1</b>	<b>Introduzione</b>	<b>1</b>
<b>2</b>	<b>Convolutional Neural Network (CNN)</b>	<b>3</b>
<b>3</b>	<b>Area under precision-recall curve (AUPRC)</b>	<b>3</b>
<b>4</b>	<b>Few-shot learning</b>	<b>4</b>
4.1	Introduzione . . . . .	4
4.2	The meta learning framework . . . . .	5
4.3	Approcci al meta-apprendimento . . . . .	6
<b>5</b>	<b>Prototypical Network</b>	<b>6</b>
<b>6</b>	<b>Relation Network</b>	<b>8</b>
<b>7</b>	<b>Preprocessing del dataset</b>	<b>10</b>
7.1	Dataset Spoken Wikipedia Corpora . . . . .	10
7.2	Le annotazioni del dataset . . . . .	10
7.3	Lettori del dataset . . . . .	12
7.4	Parole degli audio . . . . .	14
7.5	Associazione delle parole con il rispettivo lettore . . . . .	17
7.6	Calcolo dello spettrogramma delle parole . . . . .	18
7.7	Salvataggio degli spettrogrammi . . . . .	19
<b>8</b>	<b>Codice Prototypical network</b>	<b>21</b>
8.1	Prototypical training . . . . .	22
8.2	Prototypical validation . . . . .	28
8.3	Prototypical test . . . . .	28
<b>9</b>	<b>Codice Relation network</b>	<b>31</b>
9.1	Relation training . . . . .	34
9.2	Relation validation . . . . .	38
9.3	Relation test . . . . .	39

# 1 Introduzione

Lo scopo della tesina è quello di riprodurre i risultati ottenuti nel paper "*Few-Shot Event Detection*"[4]. L'argomento centrale dello studio è l'individuazione di eventi sonori percettivamente simili all'interno di una registrazione. Varie applicazioni di questo algoritmo possono essere la rilevazione di particolari suoni nella musica o la rimozione di parole di riempimento nei podcast. Solitamente questo processo avviene manualmente risultando in un compito difficile e tedioso.

I classici modelli di deep-learning per la determinazione di suoni richiedono una grande mole di dati che funge da esempio. In questo modo la rete è capace di riconoscere parole sulle quali si è allenata.

Nell'approccio few-shot invece, è necessario un piccolo dataset di riferimento. La rete non sarà allenata a riconoscere i suoni che ha ascoltato nel training ma assumerà la capacità di riconoscere la somiglianza fra due suoni che sta analizzando.

Le reti few-shot di solito sono state utilizzate per un set chiuso dove in un *task* di classificazione veniva presentata una query e confrontata con  $K$  istanze di  $C$  classi, con  $C$  fisso. Questo metodo è chiamato C-way K-shot.

Il paper di riferimento invece, cerca di applicare una rete few-shot in un contesto più ampio in cui è necessario riconoscere una parola non vista in precedenza in una sequenza di suoni non classificati in precedenza dalla rete.

Per fare questo, l'idea è quella di costruire un set positivo e un set negativo con i quali confrontare la query, come mostrato in 1. Mentre il set positivo è costituito da istanze della stessa parola, il set negativo comprende vari campioni di parole diverse e rappresenta un generico esempio di tutto ciò che non comprende la parola da cercare.

Prima di fare questo però, la rete deve "imparare ad imparare": verrà quindi sottoposta a una serie di task classici di few shot nei quali la rete deve riconoscere a quale classe appartiene una query avendo come riferimento  $K$  istanze di  $C$  classi, che costituiscono il support set.

Il support set e la query può essere diverso ad ogni episodio, generalizzando il più possibile l'evento e allenando la capacità della rete di *recognoscere la somiglianza* e non di riconoscere le parole.

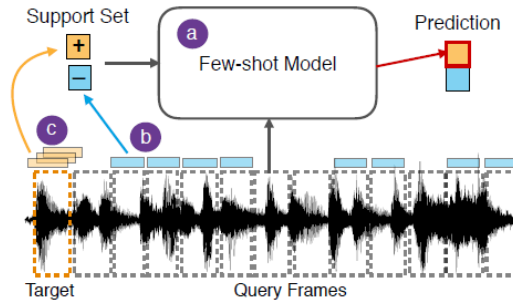


Figura 1: Metodo proposto per il few-shot sound event detection. (a) Applicazione del modello few-shot, (b) costruzione del set di esempi negativi, in blu, e (c) data augmentation per la generazioni di più esempi positivi, in arancione. [4]




Figura 2: Modello few-shot learning nel caso 5-way 2-shot. [4]

## 2 Convolutional Neural Network (CNN)

Una rete neurale convoluzionale è una rete feedforward pensata per applicazioni che richiedono l'elaborazione di immagini o di grandi moli di dati. L'ingresso della rete è costituito da una o più matrici che attraversano delle fasi di convoluzione che ne riducono le dimensioni. I filtri di convoluzione sono detti kernel o di pooling. Infine, il risultato viene passato a una rete fully connected che ha il compito di classificazione.

La prima parte del filtro consiste nella convoluzione dell'immagine in ingresso con una serie di kernel i cui parametri vengono allenati. Il filtro viene traslato in entrambe le dimensioni della matrice producendo una serie di feature bidimensionali. Il parametro *stride* definisce il passo con cui il kernel viene traslato sulla matrice di ingresso. Solitamente, viene effettuato uno zero-padding sui contorni del volume in modo da poter caratterizzare anche i valori che si trovano ai bordi delle matrici. In seguito alla convoluzione viene applicata una funzione non-lineare come ad esempio una sigmoide o una ReLu con lo scopo di aumentare la proprietà di non linearità.

Il pooling layer è uno strato della rete che ha lo scopo di ridurre le dimensioni della matrice prodotta dal convolutional layer. Combinando gruppi di elementi della matrice (solitamente 2x2) restituisce il valore massimo tra essi, che andrà a sostituire il blocco stesso.

## 3 Area under precision-recall curve (AUPRC)

Nella fase di test, la rete elabora una predizione dell'output a partire da un ingresso noto che poi viene confrontata con il valore effettivo. Nel nostro caso è presente un positive set e un negative set, si tratta quindi di classificazione binaria. Il confronto tra predizione e label può produrre quattro risultati:

- Vero Negativo (TN): il valore reale è negativo e il valore predetto è negativo;
- Vero Positivo (TP): il valore reale è positivo e il valore predetto è positivo;
- Falso Negativo (FN): il valore reale è positivo e il valore predetto è negativo;
- Falso Positivo (FP): il valore reale è negativo e il valore predetto è positivo;

Questi valori vanno a comporre la confusion matrix. Nel nostro caso siamo interessati a Precision e Recall.

Il parametro Precision rappresenta quanti tra i casi predetti come positivi sono realmente positivi.

Il parametro Recall indica quanti tra i casi realmente positivi è stato predetto in modo corretto.

$$Precision = \frac{TP}{TP + FP} \quad (1)$$

$$Recall = \frac{TP}{TP + FN} \quad (2)$$

Consideriamo un vettore contenente le probabilità che una serie di query appartengono a una classe.

Considerando una soglia di decisione e confrontando con un altro vettore contenente i valori desiderati (1 se la query corrisponde alla classe e 0 altrimenti) è possibile ottenere una coppia di valori di precision e recall.

A questo punto ordiniamo il vettore con valori decrescenti. Consideriamo come soglia il valore di probabilità presente al primo elemento e calcoliamo precision e recall. Poi, spostiamo la soglia al valore del secondo elemento e calcoliamo altri valori. Continuando in questo modo si può ottenere una curva considerando alle ascisse i valori di recall e come ordinate i valori di precision.

Calcolando l'area sottesa dalla curva si riceve il valore detto Area under precision-recall curve (AUPRC). Questo valore è molto utile quando i dati sono sbilanciati e, in una classificazione binaria, siamo più interessati al riconoscimento di una classe in particolare.

## 4 Few-shot learning

(<https://www.borealisai.com/en/blog/tutorial-2-few-shot-learning-and-meta-learning-i/>)

### 4.1 Introduzione

Gli esseri umani possono riconoscere nuove classi di oggetti partendo da pochissimi esempi. Tuttavia, la maggior parte delle tecniche di machine learning richiedono migliaia di esempi per ottenere prestazioni simili a quelle umane. L'obiettivo del *few-shot learning* è classificare i nuovi dati dopo aver visto solo pochi esempi di training. Nel caso estremo, potrebbe esserci solo un singolo esempio per ogni classe (*one shot learning*). In pratica, il few-shot

learning è utile quando è difficile trovare esempi di training (ad es. casi di una malattia rara) o quando il costo dell'etichettatura dei dati è elevato.

L'apprendimento few-shot viene solitamente studiato utilizzando la classificazione *N-way-K-shot*. L'obiettivo è quello di discriminare le  $N$  classi composte da  $K$  esempi ciascuna. Una tipica dimensione del problema potrebbe essere quella di discriminare tra  $N = 10$  classi con solo  $K = 5$  campioni ciascuno di training. Non possiamo allenare un classificatore usando metodi convenzionali; qualsiasi algoritmo di classificazione moderno dipenderà da molti più parametri rispetto agli esempi di addestramento e generalizzerà male.

Se i dati non sono sufficienti per ridurre il problema, una possibile soluzione è acquisire esperienza da altri problemi simili. A tal fine, la maggior parte degli approcci caratterizza l'apprendimento a breve termine con un problema di meta-apprendimento.

## 4.2 The meta learning framework

Nel framework di apprendimento classico, impariamo come classificare dai dati di training e valutiamo i risultati utilizzando i dati di test. Nel quadro del meta-apprendimento, *impariamo come imparare* a classificare in base a una serie di *training task* e valutiamo utilizzando una serie di test task; In altre parole, usiamo un insieme di problemi di classificazione per aiutare a risolvere altri insiemi non correlati.

Qui, ogni attività imita lo scenario few-shot, quindi per la classificazione  $N$ -way- $K$ -shot, ogni attività include  $N$  classi con  $K$  esempi ciascuna. Questi sono noti come support set per il task e vengono utilizzati per apprendere come risolvere il task. Inoltre, esistono ulteriori esempi delle stesse classi, note come set di query, utilizzate per valutare le prestazioni del task corrente. Ogni task può essere completamente unico; potremmo non vedere mai le classi di un task in nessuno degli altri. L'idea è che il sistema veda ripetutamente istanze (task) durante l'addestramento che corrispondono alla struttura dell'attività finale di few-shot, ma che contengono classi diverse.

Ad ogni fase del meta-apprendimento, aggiorniamo i parametri del modello in base ad un training task selezionato casualmente. La funzione di loss è determinata dalle prestazioni di classificazione sul set di query del task, in base alla conoscenza acquisita dal relativo set di supporto. Poiché la rete viene sottoposta ad un compito diverso in ogni fase temporale, deve imparare a discriminare le classi di dati in generale, piuttosto che un particolare sottoinsieme di classi.

Per valutare le prestazioni in pochi colpi, utilizziamo una serie di attività di test. Ciascuno contiene solo classi invisibili che non erano in nessuna delle

attività di formazione. Per ciascuno, misuriamo le prestazioni sul set di query in base alla conoscenza del loro set di supporto.

### 4.3 Approcci al meta-apprendimento

Gli approcci al meta-apprendimento sono diversi e non c'è consenso sull'approccio migliore. Tuttavia, esistono tre famiglie distinte, ognuna delle quali sfrutta un diverso tipo di conoscenza a priori:

- Conoscenze a priori sulla somiglianza: apprendiamo degli embedding nei training task che tendono a separare classi diverse anche quando non sono visibili.
- Conoscenze a priori sull'apprendimento: utilizziamo le conoscenze a priori per vincolare l'algoritmo di apprendimento a scegliere parametri che generalizzino bene da pochi esempi.
- Conoscenza a priori dei dati: sfruttiamo le conoscenze a priori sulla struttura e la variabilità dei dati e questo ci consente di apprendere modelli praticabili da pochi esempi.

## 5 Prototypical Network

L'approccio si basa sull'idea che esiste un embedding in cui i punti delle istanze di una classe si raggruppano attorno a una singola rappresentazione prototipo per ogni classe. Nella classificazione few-shot per ogni episodio viene fornito un support set di  $N$  esempi etichettati  $S = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$  dove  $\mathbf{x}_i \in \mathbb{R}^D$  rappresenta il vettore  $D$ -dimensionale della feature (nel nostro caso spettrogrammi di dimensione  $128 \times 51$ ) e  $y_i \in \{1, \dots, K\}$  la rispettiva label.  $S_k$  denota il set di esempi etichettati con la classe  $k$ .

La rete Prototypical calcola una rappresentazione  $M$ -dimensionale  $\mathbf{c}_k$ , o *prototipo*, di ogni classe tramite una funzione di embedding  $f_\phi : \mathbb{R}^D \rightarrow \mathbb{R}^M$  con parametri da allenare  $\phi$ . La funzione di embedding è rappresentata da una rete convoluzionale. Ogni prototipo è il vettore media tra gli embedding delle istanze della stessa classe.

$$\mathbf{c}_k = \frac{1}{|S_k|} \sum_{(\mathbf{x}_i, y_i) \in S_k} f_\phi(\mathbf{x}_i) \quad (3)$$

Data una funzione distanza  $d : \mathbb{R}^M \times \mathbb{R}^M \rightarrow [0, +\infty)$ , la rete Prototypical calcola la relazione di una query  $\mathbf{x}$  rispetto ai prototipi tramite la funzione



softmax delle distanze prese con segno negativo.

$$p_\phi(y = k|\mathbf{x}) = \frac{\exp(-d(f_\phi(\mathbf{x}), \mathbf{c}_k))}{\sum_k' \exp(-d(f_\phi(\mathbf{x}), \mathbf{c}_k'))} \quad (4)$$

Il processo di training avviene minimizzando il negativo del logaritmo della probabilità  $J(\phi) = -\log(p_\phi(y = k|\mathbf{x}))$  considerando la distanza fra query e il prototipo della sua classe. Gli episodi di training sono formati campionando  $C$  classi di parole da un lettore e selezionando per ognuna casualmente  $K$  istanze e  $Q$  query.




Figura 3: Reti Prototypical negli scenari few-shot e zero-shot. (a): i prototipi few-shot  $\mathbf{c}_k$  sono calcolati come la media degli embedding del support set per ogni classe. (b): i prototipi zero-shot  $\mathbf{c}_k$  sono prodotti facendo l'embedding dei metadati  $\mathbf{v}_k$ . In entrambi i casi i punti degli embedding delle query sono classificati facendo il softmax sulle distanze del prototipo delle classi:  $p_\phi(y = k|\mathbf{x}) \propto \exp(-d(f_\phi(\mathbf{x}), \mathbf{c}_k))$ . [2]

## 6 Relation Network

La rete Relation ha lo scopo di associare due istanze alla volta per determinare la loro similarità. Questo viene effettuato concatenando gli embedding di più istanze in un unico elemento che sarà dato in ingresso a una rete decisionale i cui parametri saranno aggiornati in modo che una concatenazione di elementi simili restituisca un risultato vicino a 1. La Relation Network è costituita da due moduli: un modulo di *embedding*  $f_\phi$  (equivalente a quello nella Prototypical) e un modulo di *relation*  $g_\phi$ , come illustrato in figura 4. Le istanze  $x_i$  del query set  $\mathcal{Q}$  e quelle  $x_j$  del support set  $\mathcal{S}$  vengono date in ingresso al modulo di embedding producendo dei vettori (feature maps)  $f_\phi(x_i)$  e  $f_\phi(x_j)$ . Questi ultimi vengono poi dati all'operatore  $\mathcal{C}(\cdot, \cdot)$  che ne fa la concatenazione:  $\mathcal{C}(f_\phi(x_i), f_\phi(x_j))$ . Le feature map concatenate passano poi attraverso il modulo di decisione che restituisce uno scalare da 0 a 1, il quale rappresenta la somiglianza tra  $x_i$  e  $x_j$ . Per il caso  $C$ -way one-shot, viene concatenata la query con le istanze delle  $C$  classi producendo  $C$  punteggi di somiglianza.

$$r_{i,j} = g_\phi(\mathcal{C}(f_\phi(x_i), f_\phi(x_j))), \quad i = 1, 2, \dots, C \quad (5)$$

Nel caso  $C$ -way K-shot invece, la query viene concatenata con la somma elemento per elemento degli embedding di ogni istanza delle classi. Quindi, in entrambi i casi i confronti  $r_{i,j}$  sono  $C$  per ogni query.

Per allenare il modello viene usato l'errore quadratico medio (MSE) in modo che l'uscita del modulo di decisione produca 1 se i vettori concatenati sono della stessa classe e 0 altrimenti.




Figura 4: Architettura della Relation Network nel caso 5-way 1-shot con un esempio di query. [3]

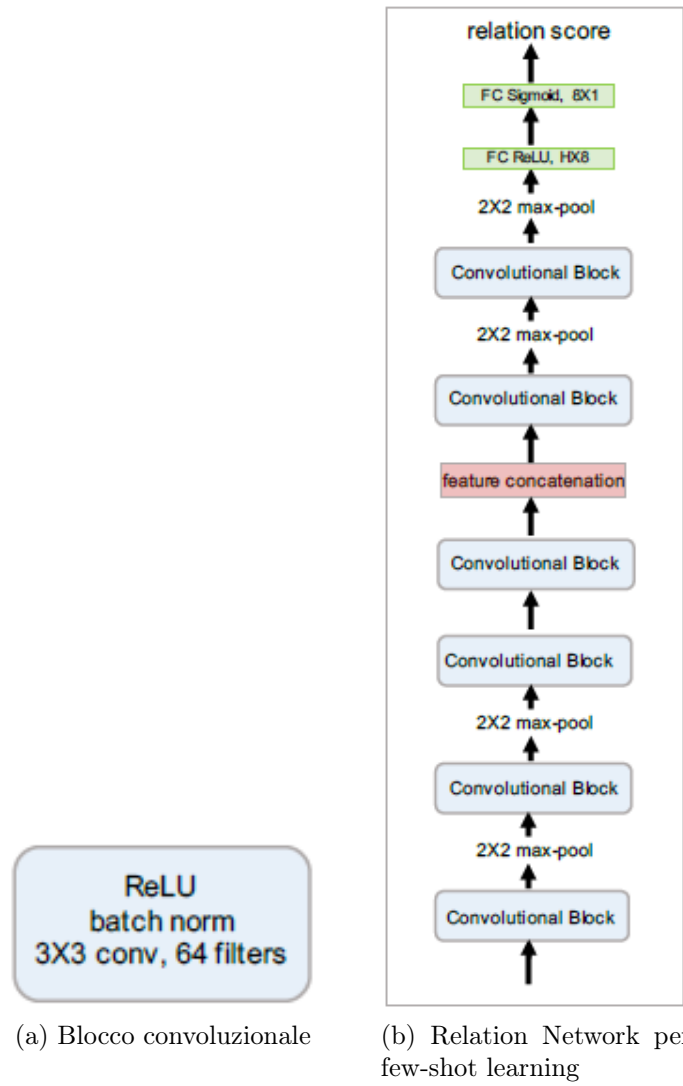


Figura 5: Architettura della Relation Network per few-shot learning (b) composta dagli elementi inclusi nel blocco convoluzionale (a). [3]

## 7 Preprocessing del dataset

### 7.1 Dataset Spoken Wikipedia Corpora

Il progetto Spoken Wikipedia unisce lettori volontari di articoli di Wikipedia. Sono disponibili centinaia di articoli in inglese, tedesco e olandese per gli utenti che non sono in grado o non vogliono leggere la versione scritta dell'articolo. Il dataset trasforma i file audio in un corpus, cioè una raccolta ordinata e completa di opere o di autori, allineato nel tempo, rendendolo accessibile per la ricerca.[1]

Questo corpus ha diverse caratteristiche importanti:

- centinaia di ore di audio allineato
- lettori eterogenei
- diversi argomenti
- genere testuale ben studiato
- le annotazioni delle parole possono essere mappate all'html originale
- allineamenti a livello di fonema

Ogni articolo è suddiviso in sezioni, frasi e token. Ogni token è normalizzato e la normalizzazione è allineata all'audio.

### 7.2 Le annotazioni del dataset

Ogni annotazione è racchiusa in un tag chiamato “**article**”, che contiene una sezione “**meta**” per i metadati, come si può vedere in 1 e una sezione “**d**”, come in 2, contenente l'articolo e le relative annotazioni.

```
<article>
  <meta>
    <link key="DC.conformsto" value="http://nats.gitlab.io/swc/schema/swc-1.0.rnc"/>
    <prop key="DC.creator" value="Spoken Wikipedia Corpus Collection Software"/>
    <prop key="DC.publisher" value="Universität Hamburg"/>
    <link key="DC.reference" value="http://nbn-resolving.de/urn:nbn:de:gbv:18-228-7-2209"/>
    <prop key="DC.type" value="dataset"/>
    <prop key="DC.license" value="CC-BY-SA"/>
    <prop key="DC.title" value="Limerence"/>
    <prop key="DC.language" value="en"/>
    <prop key="DC.identifier" value="Limerence"/>
    <prop key="DC.date.read" value="2005-04-29 00:00:00"/>
    <link key="DC.source" value="https://en.wikipedia.org/wiki/Limerence"/>
    <prop key="DC.source.wikiID" value="154147"/>
    <prop key="DC.source.revision" value="791627969"/>
    <link key="DC.source.text" value="https://en.wikipedia.org/w/index.php?title=Limerence&oldid=13811989"/>
    <link key="DC.source.audio" value="https://upload.wikimedia.org/wikipedia/commons/aa/Limerence.ogg" group="audiol"/>
    <prop key="DC.source.audio.offset" value="0.0" group="audiol"/>
    <link key="DC.source.audio.page" value="https://en.wikipedia.org/w/index.php?title=File%3aLimerence.ogg" group="audiol"/>
```

```

<link key="DC.source.audio.date" value="2007-09-14 19:23:05" group="audio1"/>
<prop key="reader.name" value="the Epopt"/>
<prop key="processing.step" value="tokenize" group="tokenize"/>
<prop key="processing.step.date" value="2017-08-10T07:44:44.095+02:00[Europe/Berlin]"
      group="tokenize"/>
<prop key="processing.step.options" value="Namespace(output=articles/Limerence/
tokenized.swc, all_sections=false, null_normalize=false, raw_output=null,
subparser_name=tokenize, lang=en, no_introduction=false, article_dir=articles/
Limerence)" group="tokenize"/>
<prop key="processing.step.git.commit.id" value="7431
dbf93f212ad828208abaf8f518fb8de11ff3" group="tokenize"/>
<prop key="processing.step.git.commit.time" value="09.08.2017 @ 15:21:55 CEST" group
="tokenize"/>
<prop key="processing.step" value="align" group="align"/>
<prop key="processing.step.date" value="2017-08-11T16:12:18.423+02:00[Europe/Berlin]"
      group="align"/>
<prop key="processing.step.options" value="Namespace(output=articles/Limerence/
aligned.swc, transcript=articles/Limerence/tokenized.swc, g2p=../model_en/model.
fst.ser, phone=false, subparser_name=align, dict=../model_en/empty.dic,
acoustic_model=../model_en/, audio=articles/Limerence/audio.wav)" group="align"
/>
<prop key="processing.step.git.commit.id" value="7431
dbf93f212ad828208abaf8f518fb8de11ff3" group="align"/>
<prop key="processing.step.git.commit.time" value="09.08.2017 @ 15:21:55 CEST" group
="align"/>
</meta>

```

Codice 1: Metadati delle annotazioni delle parole in un audio

Il documento, contrassegnato dal tag “d”, può contenere parti diverse, ciascuna spiegata di seguito. La sezione “extra” contiene il testo che abbiamo incluso ma non fa parte dell’articolo, “ignored” contiene ciò che fa parte del testo ma viene ignorato per l’allineamento, “section” contiene un titolo e un contenuto, “p” contiene un paragrafo e “s” una frase che a sua volta contiene dei token “t”. In quest’ultimo è contenuta la singola parola originale e le normalizzazioni. Per esempio, la punteggiatura non ha annotazioni di normalizzazione in quanto non è pronunciata, ma il numero 500 ne ha due - “cinque” e “cento”. un token stesso non ha allineamento, solo la sua normalizzazione “n” è allineata. La normalizzazione ha una “pronunciation” e può avere un tempo di “start” ed “end”, se è allineata. La normalizzazione, a sua volta, può contenere dei fonemi “ph”.

```

<d>
<extra text="LimerenceFrom wikipedia, the free encyclopedia at e n dot wikipedia dot
org.">
<s text="LimerenceFrom wikipedia, the free encyclopedia at e n dot wikipedia dot org
.">
<t text="LimerenceFrom">
<n pronunciation="LimerenceFrom" start="140" end="1190"/>
</t>
<t text="wikipedia">
<n pronunciation="wikipedia" start="1250" end="1950"/>
</t>
<t text=","/>
<t text="the">
<n pronunciation="the" start="1950" end="2070"/>
</t>
<t text="free">
<n pronunciation="free" start="2070" end="2300"/>
</t>
<t text="encyclopedia">
<n pronunciation="encyclopedia" start="2300" end="3220"/>
</t>
<t text="at">
<n pronunciation="at"/>
</t>
<t text="e">
<n pronunciation="e" start="3490" end="3710"/>
</t>

```

### 7.3 Lettori del dataset

Il dataset Spoken Wikipedia Corpora contiene un totale di 1340 audio di diversi lettori, ma nel progetto vengono presi solo gli audio che contengono annotazioni a livello di parola. In questo modo vengono presi solo 208 lettori e partizionati come in [4] con un rapporto 138 : 15 : 30 tra lettori di training, validation e test. I lettori e le parole sono state estratte dai file “aligned.swc” contenuti in ogni audio e, successivamente, salvati in diversi file json. Per la gestione dei json sono state create due funzioni utili per la lettura e scrittura come mostrato nel codice 3.

```
1 import json
2
3 def write_json_file(filename, list_of_dict, indent = 0):
4     f = open(filename, "w")
5     f.write(json.dumps(list_of_dict, indent = indent))
6     f.close
7
8 def read_json_file(filename):
9     f = open(filename, "r")
10    list_of_dict = json.load(f)
11    f.close
12    return list_of_dict
```

Codice 3: json\_manager.py

Il codice 4 salva un file json chiamato “readers\_paths.json” formato dalle chiavi “reader\_name” e “folder” i cui valori sono rispettivamente il nome del lettore e le cartelle in cui sono salvati i file audio registrati dal relativo lettore, come si può vedere nel json 5. Questo codice, usando la libreria `xml.etree.ElementTree` e la funzione `ET.parse`, rappresenta l'intero documento XML come un albero. La funzione `getroot` ne trova la radice e, successivamente, si scorre l'albero iterando finché non si trova il tag “prop”, in cui è contenuta la chiave “reader.name”. Inoltre, si effettua un controllo sul nome del lettore perché può capitare che questo venga salvato nel file “aligned.swc” in modi diversi. Ad esempio, in alcuni file si può trovare nella chiave “reader.name” il valore “:en:user:alexkillby|alexkillby”, mentre in altri solo “alexkillby” oppure si può trovare “user:popularoutcast”, mentre in altri solo “popularoutcast”. Una volta noto il nome del lettore si vede se è già presente nella lista di dizionari e se è un lettore nuovo lo si aggiunge con il relativo nome del file audio, mentre se il lettore era già presente si aggiunge solamente il nome del file audio.

```

1 import xml.etree.ElementTree as ET
2 from tqdm import tqdm
3 import os
4 import json
5 from json_manager import *
6
7 # Initialize list with empty dictionaries
8 readers = []
9
10 source_path = "./Dataset/English spoken wikipedia/english/"
11 filename = "aligned.swc"
12
13 # search for readers for each folder
14 for audio_path in os.scandir(source_path):
15     # save only folder name from entire path
16     folder = os.path.basename(audio_path)
17     if (os.path.exists(source_path + "/" + folder + "/" + filename)):
18         # parse the xml file "aligned.swc"
19         tree = ET.parse(source_path + "/" + folder + "/" + filename)
20         # getroot returns the root element for this tree
21         root = tree.getroot()
22         #root.iter creates a tree iterator with the current element as the root.
23         # The iterator iterates over this element and all elements below it, in
24         # document (depth first) order.
25         for property in root.iter(tag = 'prop'):
26             # if the key "reader.name" exists
27             if (property.attrib['key'] == 'reader.name'):
28                 # save the reader name taking the value of the attribute
29                 reader_name = property.attrib['value'].lower()
30                 # fix readers names that contain "user:"
31                 if ("user:" in reader_name):
32                     # fix readers names that contain "|"
33                     if ("|" in reader_name):
34                         # example reader_name = [[:en:user:alexkillby|alexkillby]] ->
35                         # reader_name = alexkillby
36                         reader_name = reader_name[reader_name.find("user:") + 5:
37                                                         reader_name.find("|")]
38                     # fix readers names that contain "|"
39                     elif ("]" in reader_name):
40                         # example reader_name = [[user:popularoutcast]] ->
41                         # reader_name = popularoutcast
42                         reader_name = reader_name[reader_name.find("user:") + 5:
43                                                         reader_name.find("]]")]
44             # if the reader is not yet on the list create a dict and append to
45             # the readers list
46             if not any(reader['reader_name'] == reader_name for reader in
47                         readers):
48                 dictionary = {'reader_name': reader_name, 'folder': [folder]}
49                 readers.append(dictionary)
50             else:
51                 # if the reader is already on the list add the folder name
52                 for reader in readers:
53                     if (reader['reader_name'] == reader_name):
54                         reader['folder'].append(folder)
55 # print the number of the readers
56 print("The readers are:", str(len(readers)))
57
58 # save a "readers_paths.json" with the name of the readers and the relative
59 # file audio folders
60 write_json_file("readers_paths.json", readers, indent = 4)

```

#### Codice 4: xml\_parser\_readers.py

```
{
  "reader_name": "the epopt",
  "folder": [
    "(I_Can%27t_Get_No)_Satisfaction",
    "Ceremonial_ship_launching",
    "Limerence",
    "Revolt_of_the_Admirals",
    "Ship_commissioning"
  ],
},
{
  "reader_name": "wodup",
  "folder": [
    "0.999..%2e",
    "Execution_by_elephant",
    "Hell_Is_Other_Robots",
    "Tom_Bosley",
    "Truthiness"
  ],
},
},
```

#### Codice 5: Formato del file readers\_paths.json

## 7.4 Parole degli audio

Il codice 6 mostra come viene creato il json 7, formato dalle chiavi “word”, “frequency”, “start” ed “end”, le quali, a loro volta, contengono la parola, il numero di volte in cui è stata ripetuta e il timestamp di inizio e fine.

Per ogni cartella del dataset SWC, se esistono i file “audio.ogg” e “aligned.swc”, si procede con il parsing del file XML, iterando l’albero fino al tag “n”, cioè fino al tag che contiene la normalizzazione della parola come spiegato in 7.2. Se è presente la chiave “start” (o, in modo equivalente, “end”), la parola viene aggiunta alla lista **words**.

Per trovare quante volte viene ripetuta la singola parola abbiamo usato la sottoclasse **Counter** della classe **dict** di Python, la quale restituisce una raccolta in cui gli elementi sono le chiavi del dizionario e il numero di ripetizioni è il loro valore. Si costruisce dunque una lista di dizionari chiamata **target\_words**, che contiene le *target words*, cioè le parole che si ripetono almeno 10 volte nel testo. [4]

Si rifà un parsing del file XML per aggiungere i timestamp di “start” e “end” ad ogni parola. Il file “word\_count.json” contiene tutte le parole che si ripetono almeno 10 volte e viene salvato all’interno di ogni cartella del dataset. Infine, si filtrano le target words, utili poi in fase di test della rete: se ci sono più di 10 parole che soddisfano la condizione di target word, si



prendono tra queste solo 10 scelte in modo random. In questo modo, si cerca di evitare di scegliere parole molto comuni o molto rare. Le target words vengono salvate nel file “target\_words.json” contenuto all’interno di ogni cartella del dataset.

```

1  import xml.etree.ElementTree as ET
2  from tqdm import tqdm
3  import os
4  import collections
5  from json_manager import *
6  import random
7
8  folder = []
9  source_path = "./Dataset/English spoken wikipedia/english/"
10 filename = "aligned.swc"
11 file_audio_name = "audio.ogg"
12
13 # iterate in each folder of the dataset
14 for folder in tqdm(os.scandir(source_path), desc = "Folder number"):
15     # initialize the list of dict "target_words"
16     target_words = []
17     if (os.path.exists(folder.path + "/" + filename) \
18         and os.path.exists(folder.path + "/" + file_audio_name)):
19         # parse the xml file aligned.swc
20         tree = ET.parse(folder.path + "/" + filename)
21         # getroot returns the root element for this tree
22         root = tree.getroot()
23         # initialize the list "words"
24         words = []
25         # root.iter creates a tree iterator with the current element as the
26         # root. The iterator iterates over this element and # all elements
27         # below it, in document (depth first) order.
28         for token_normalization in root.iter(tag = 'n'):
29             # we take only the words with the timestamp, so only if there is
30             # 'start' (or 'end') tag
31             if 'start' in token_normalization.keys():
32                 # add every word with "start" key
33                 words.append(token_normalization.attrib['pronunciation'].
34                             lower())
35
36         # collections.Counter stores elements as dictionary keys, and their
37         # counts are stored as dictionary values.
38         unique_words = collections.Counter(words)
39         # for each key (word) in "unique_words" append a new target_word if
40         # the number of occurrence is at least 10
41         for key in unique_words.keys():
42             # we only consider words that occur at least 10 times in the
43             # recording. Note that unique_words[key] is the word frequency
44             if (unique_words[key] >= 10):
45                 # add a new target word
46                 target_words.append({'word' : key, \
47                                     'frequency' : unique_words[key], \
48                                     'start' : [], \
49                                     'end' : []})
50
51         # for each "target_words" append the relative "start" and "end"
52         # timestamp
53         for token_normalization in root.iter(tag = 'n'):
54             # we take only the words with the timestamp, so only if there is
55             # 'start' (or 'end') tag
56             if 'start' in token_normalization.keys():
57                 # iterate over the "target_words"

```

```

54         for target_word in target_words:
55             # add start and end timestamp only to the relative
56             # "target_word"
57             if target_word['word'] == token_normalization.attrib['
                pronunciation'].lower():
58                 target_word['start'].append(int(token_normalization.
                    attrib['start']))
59                 target_word['end'].append(int(token_normalization.
                    attrib['end']))
60
61         write_json_file(folder.path+"/word_count.json", target_words, indent
            = 4)
62         # If there are more than 10 words that occur at least 10 times in
63         # the recording, we sort the words by their number of occurrences,
64         # divide the sorted list into 10 equally sized bins, and sample
65         # one keyword per bin.
66         if (len(target_words) >= 10):
67             target_words = random.sample(target_words, 10)
68         # save the "target_words.json"
69         write_json_file(folder.path+"/target_words.json", target_words,
            indent = 4)

```

Codice 6: find\_target\_words.py

```

{
    "word": "i",
    "frequency": 12,
    "start": [
        660,
        8800,
        115050,
        ...
    ],
    "end": [
        870,
        8940,
        115240,
        ...
    ]
},
{
    "word": "the",
    "frequency": 75,
    "start": [
        4160,
        49930,
        53680,
        ...
    ],
    "end": [
        4320,
        50030,
        53710,
        ...
    ]
},
...
],
}

```

Codice 7: Formato del file word\_count.json

## 7.5 Associazione delle parole con il rispettivo lettore

I file “readers\_paths.json” e “word\_count.json” vengono successivamente usati per salvare le parole di ogni lettore, il nome della relativa cartella in cui vengono pronunciate e i timestamp di inizio e fine della parola per ogni cartella come mostrato nel json 9. Il codice 8 legge il nome di ogni lettore dal json precedentemente salvato, successivamente per ognuna delle cartelle del lettore viene usato “word\_count.json” per ottenere tutte le parole dell’audio e i relativi timestamp.

Viene salvato infine il file “readers\_words.json” che contiene per ogni lettore le parole pronunciate, per ognuna di queste l’audio in cui vengono enunciate e per ogni audio i timestamp di inizio e fine.

```
1  from tqdm import tqdm
2  import os
3  from json_manager import *
4
5  source_path = "./Dataset/English spoken wikipedia/english/"
6  # read the json that contains the readers name and their audio folders
7  readers = read_json_file("readers_paths.json")
8  # initialize a list of dict
9  readers_words = []
10 # for each reader search the word spoken by the reader
11 for reader in tqdm(readers):
12     # create a dict with 'reader_name' and 'words' keys
13     new_readers_words = {'reader_name' : reader['reader_name'], \
14                          'words' : [] }
15
16     # for each reader create a new dict for words
17     words_per_reader = []
18     # flag to signal if "word_count.json" exists
19     json_file_exist = False
20     # search for each folder the file "word_count.json"
21     for reader_folder in reader['folder']:
22         if (os.path.exists(source_path + "/" + reader_folder + "/word_count.
23                               json")):
24             # "word_count.json" exists
25             json_file_exist = True
26             # read "word_count.json"
27             recording_words = read_json_file(source_path + "/" +
28                                               reader_folder + "/word_count.json")
29             # for each audio folder create a new list of dict
30             folder_per_word = []
31             # for each word in the audio save the folder, start and end
32             # timestamps
33             for word in recording_words:
34                 # create a dict with 'folder', 'start' and 'end' keys
35                 folder_per_word = {'folder' : reader_folder, \
36                                    'start' : word['start'], \
37                                    'end' : word['end']}
38                 # if the word is not yet in the list add the word
39                 if not any (word['word'] == word_per_reader['word'] for
40                             word_per_reader in words_per_reader):
41                     words_per_reader.append({'word' : word['word'], \
42                                              'folders' : [folder_per_word]})
43
44     # otherwise add 'start' and 'end' if the "reader_folder" is
```

```

41         # in word_per_reader['folders'] or add the "folder_per_word"
42         else:
43             for word_per_reader in words_per_reader:
44                 if word['word'] == word_per_reader['word']:
45                     if reader_folder in word_per_reader['folders']:
46                         for folder in word_per_reader['folders']:
47                             if reader_folder == folder['folder']:
48                                 folder['start'] += word['start']
49                                 folder['end'] += word['end']
50                     else:
51                         word_per_reader['folders'].append(
52                             folder_per_word)
53     # if "word_count.json" exists add the new reader to "training_readers"
54     # list
55     if (json_file_exist):
56         new_readers_words['words'] = words_per_reader
57         readers_words.append(new_readers_words)
58 # save a "readers_words.json" with the name of the readers and the relative
59 # words spoken
60 write_json_file("readers_words.json", readers_words, indent = 0)

```

Codice 8: words\_per\_reader.py

```

"reader_name": "wodup",
"words": [
    {
        "word": "the",
        "folders": [
            {
                "folder": "0.999..%2e",
                "start": [
                    6950,
                    1029740,
                    1032520,
                    ...
                ],
                "end": [
                    7190,
                    1029880,
                    1032620,
                    ...
                ]
            },
            {
                "folder": "Execution_by_elephant",
                "start": [
                    3600,
                    10680,
                    ...
                ]
            }
        ]
    }
]

```

Codice 9: Formato del file readers\_words.json

## 7.6 Calcolo dello spettrogramma delle parole

Per ogni istanza delle parole, prendiamo una finestra di mezzo secondo centrata sulla parola, calcoliamo lo spettrogramma mel da 128 bin e lo portiamo

scala logaritmica. La funzione `compute_melspectrogram`, mostrata nel codice 10, usando la libreria *librosa*, calcola gli spettrogrammi da dare in input ai modelli della rete neurale. I file audio, originalmente campionati ad una frequenza di 44.1 kHz, sono sottocampionati a 16 kHz. Per calcolare lo spettrogramma, usiamo una lunghezza della finestra di 25 ms, un hop size di 10 ms e una FFT di 64 ms. Lo spettrogramma è contenuto in una matrice di dimensioni  $128 \times 51$ , poiché il numero di bande mel è 128 e la parola di mezzo secondo viene divisa in finestre da 10 ms.

```

1  import librosa
2
3  def compute_melspectrogram(filename, word_center):
4      # audio recordings are downsampled to a sampling rate of 16 kHz.
5      sample_rate = 16000
6      #librosa.load loads the audio file as a floating point time series.
7      # y: audio time series, sr: sample rate
8      y, _ = librosa.load(path = filename, sr = sample_rate, offset =
          word_center - 0.25, duration = 0.5)
9
10     # We use a window length of 25 ms, hop size of 10 ms and a fast Fourier
11     # transform size of 64 ms.
12     window_length = int(0.025*sample_rate)
13     hop_size = int(0.01*sample_rate)
14     fft_size = int(0.064*sample_rate)
15     # For each word instance, we take a half-second context window centered
16     # on the word and compute a 128 bin log-mel-spectrogram
17     mels_number = 128
18     # librosa.feature.melspectrogram computes a mel-scaled spectrogram.
19     mel_spectrogram = librosa.feature.melspectrogram(y, sr = sample_rate,
        n_fft = fft_size, hop_length = hop_size, win_length = window_length,
        n_mels = mels_number)
20     # librosa.power_to_db converts a power spectrogram to a dB-scale
21     # spectrogram.
22     log_mel_spectrogram = librosa.power_to_db(mel_spectrogram)
23
24     return log_mel_spectrogram

```

Codice 10: `mel_spectrogram.py`

Il risultato della funzione `log_mel_spectrogram` applicato alla parola “stones” pronunciata tra 50.35 s e 50.78 s nell’audio contenuto nella cartella “I can’t get no satisfaction” è mostrato nella figura 6. Come ingresso della funzione viene dato il percorso del file “audio.ogg” contenuto nella cartella “I can’t get no satisfaction” e come centro della parola “stones” il tempo  $\frac{50.78+50.35}{2}$  s.

## 7.7 Salvataggio degli spettrogrammi




Figura 6: Spettrogramma di mezzo secondo centrato sulla parola “stones” pronunciata nell’audio “I can’t get no satisfaction” dopo 50.35 secondi.

## 8 Codice Prototypical network

```
1 import torch.nn as nn
2
3 def count_parameters(model):
4     return sum(p.numel() for p in model.parameters() if p.requires_grad)
5
6 def conv_block(in_channels, out_channels):
7
8     return nn.Sequential(
9         nn.Conv2d(in_channels, out_channels, 3, padding=1),
10        nn.BatchNorm2d(out_channels),
11        nn.ReLU(),
12        nn.MaxPool2d(2)
13    )
14
15 class Protonet(nn.Module):
16     def __init__(self):
17         super(Protonet, self).__init__()
18         self.encoder = nn.Sequential(
19             conv_block(1, 64),
20             conv_block(64, 64),
21             conv_block(64, 64),
22             conv_block(64, 64)
23         )
24     def forward(self, x):
25         (num_samples, mel_bins, seq_len) = x.shape
26         #print("x.shape:", x.shape)
27         # tensor 3D to tensor 4D with 3rd dimension = 1
28         x = x.view(-1, 1, mel_bins, seq_len)
29         #print("x.view:", x.shape)
30         x = self.encoder(x)
31         #print("x.encoder:", x.shape)
32         return x.view(x.size(0), -1)
```

Codice 11: protonet.py

La CNN al che funge da rete di embedding per la Prototypical Network è costituita da 4 strati convoluzionali. Il primo di essi ha come ingresso un singolo canale e come uscita 64 mentre i tre successivi traspongono 64 canali in altri 64. Ogni blocco convoluzionale ha 4 fasi:

- `nn.Conv2d(in_channels, out_channels, 3, padding=1)`: Convoluzione bidimensionale con un kernel 3x3 i cui parametri vengono aggiornati ad ogni backward. Viene effettuato un padding di zeri ai bordi dell'ingresso.
- `nn.BatchNorm2d(out_channels)`: La batch normalization è un metodo utilizzato per rendere le reti neurali artificiali più veloci e stabili attraverso la normalizzazione degli input dei livelli con re-centering and re-scaling.
- `nn.ReLU()`: il rettificatore è una funzione di attivazione definita come la parte positiva del suo argomento.  $f(x) = \max(0, x)$

- `nn.MaxPool2d(2)`: Il max-pooling è un metodo per ridurre la dimensione di un'immagine, suddividendola in blocchi e tenendo solo quello col valore più alto.

Al termine dei blocchi viene effettuato il reshape dell'uscita schiacciandola in una sola dimensione, in modo da avere embedding vettoriali.

## 8.1 Prototypical training

```

1 def get_training_validation_readers(features_folder, C):
2     """
3     get_training_validation_readers returns training and validation readers
4     from the .
5     From the training and validation readers, it takes only the readers with
6     at least C words
7     and split the list in training readers and validation readers.
8
9     Parameters:
10    features_folder (list of string): list of the path of the training and
11    validation
12    C (int): number of classes
13
14    Returns:
15    training_readers (list of string): list of the training readers paths
16    validation_readers (list of string): list of the validation readers paths
17    """
18    readers_path = []
19    train_val_readers = []
20    # scan each reader folder in the feature_folder
21    for entry in os.scandir(features_folder):
22        # create a list of reader names
23        readers_path.append(entry.path)
24    for reader_path in readers_path:
25        words = []
26        for word in os.scandir(reader_path):
27            # create a list containing the path of the words
28            words.append(word.path)
29        if (len(words) >= C):
30            train_val_readers.append(reader_path)
31    train_val_readers = random.sample(train_val_readers, len(train_val_readers))
32    training_readers = train_val_readers[:int(138/153*len(train_val_readers))]
33    validation_readers = train_val_readers[int(138/153*len(train_val_readers)):]
34    return training_readers, validation_readers

```

Codice 12: `get_training_validation_readers`

La funzione `get_training_validation_readers`, a partire dalla lista di lettori di training/validation, seleziona quelli che hanno almeno un numero di parole diverse pari a  $C$  e li suddivide tra training e validation seguendo il rapporto usato in [4] 138/153 e 15/153. Per fare ciò scorre l'elenco delle directory dei lettori e salva su un array le parole a loro associate. Al termine di questa operazione, se il numero di parole è almeno  $C$  il lettore è ritenuto



valido e il suo nome viene aggiunto a una lista. Infine la lista viene scissa come spiegato sopra.

```
1 from tqdm import trange, tqdm
2 import torch
3 import numpy as np
4 import scipy
5 from scipy import io
6
7
8 if torch.cuda.is_available():
9     device = torch.device("cuda")
10    print("Device: {}".format(device))
11    print("Device name: {}".format(torch.cuda.get_device_properties(device).
12        name))
13 else:
14     device = torch.device("cpu")
15
16 C = 10 # classes
17 K = 5 # instances per class
18 Q = 16 # query set size
19
20 model = Protonet()
21 if torch.cuda.is_available():
22     model.to(device='cuda')
23
24 print("Model parameters: {}".format(count_parameters(model)))
25
26 optim = torch.optim.Adam(model.parameters(), lr = 0.001)
27
28 training_readers, validation_readers = get_training_validation_readers("/
29     content/drive/MyDrive/Few-Shot-Sound-Event-Detection/
30     Training_validation_features/", C)
31
32 print ("Training...")
33
34 last_accuracy = 0.0
35 train_loss = []
36 train_acc = []
37
38 # To construct a C-way K-shot training episode, we randomly sample a reader
39 # from the training set,
40 # sample C word classes from the reader, and sample K instances per class as
41 # the support set.
42
43 for episode in trange(60000, desc = "episode", position = 0, leave = True):
44     query, support = batch_sample(training_readers, C, K, Q)
45     if torch.cuda.is_available():
46         support = support.to(device='cuda')
47         query = query.to(device='cuda')
48
49     model.train()
50     optim.zero_grad()
51     loss_out, acc_val = loss(support, query, model)
52
53     loss_out.backward()
54     optim.step()
55
56     train_loss.append(loss_out.item())
57     train_acc.append(acc_val.item())
```

```

54
55     if (episode+1)%5000 == 0:
56         valid_loss = []
57         valid_acc = []
58         print ("\nValidation...")
59
60         model.eval()
61
62         for validation_episode in range(1000):
63             query, support = batch_sample(validation_readers, C, K, Q)
64             if torch.cuda.is_available():
65                 support = support.to(device='cuda')
66                 query = query.to(device='cuda')
67
68             val_loss, acc_val = loss(support, query, model)
69             optim.step()
70
71             valid_loss.append(val_loss.item())
72             valid_acc.append(acc_val.item())
73
74         print("\nValidation accuracy: {}".format(np.mean(valid_acc)))
75
76         if np.mean(valid_acc) > last_accuracy:
77
78             torch.save({
79                 'epoch': episode+1,
80                 'model_state_dict': model.state_dict(),
81                 'optimizer_state_dict': optim.state_dict(),
82                 'train_loss': train_loss,
83                 'train_acc': train_acc,
84                 'valid_loss': valid_loss,
85                 'valid_acc': valid_acc,
86                 'avg_loss_tr': np.mean(train_loss),
87                 'avg_acc_tr': np.mean(train_acc),
88                 'avg_loss_val': np.mean(valid_loss),
89                 'avg_acc_val': np.mean(valid_acc),
90                 }, "/content/drive/MyDrive/Few-Shot-Sound-Event-Detection/
                    Modelli-Prototypical-Network/prototypical_model_C{}_K{}.pt
                    ".format(C, K))
91
92             last_accuracy = np.mean(valid_acc)
93
94             scipy.io.savemat('/content/drive/MyDrive/Few-Shot-Sound-Event-
                    Detection/Modelli-Prototypical-Network/prototypical_results_C{}_
                    _K{}.mat'.format(C, K), {'train_loss': train_loss, 'train_acc'
                    : train_acc, 'valid_loss': valid_loss, 'valid_acc': valid_acc})

```

Codice 13: protonet\_training.py

Il primo for rappresenta l'inizio degli episodi. Il numero totale di iterazioni è 60000 come in [4]; per ogni episodio viene richiamata la funzione `batch_sample`. Essa campiona a caso uno dei lettori di training e di questo seleziona casualmente C parole. Per ognuna di queste parole si ricava il numero di istanze presenti del dataset. Viene inizializzato un vettore con gli indici di queste e ne vengono campionati K+Q in `index`. Poi, iterando, gli spettrogrammi il cui indice è presente in `index` vengono salvati e divisi in K istanze del support set e Q istanze del query set.

```

1  import os
2  import numpy
3  import random
4
5  def batch_sample(features, C, K, Q = 16):
6      """
7      batch_sample returns the support and query set.
8      It reads each folder in feature_folder and load the tensor with the
9      spectrograms of the word.
10     Then random sample the instances (spectrograms) of the word to get only
11     K+Q spectrograms.
12     The first K spectrograms compose the support set and the last Q ones
13     compose the query set.
14
15     Parameters:
16     features (list): training/validation features paths
17     C (int): class size
18     K (int): support set size
19     Q (int): query set size (default: 16)
20
21     Returns:
22     support (torch.FloatTensor): support set
23     query (torch.FloatTensor): query set
24     """
25     # initialize support tensor of dimension 0 x K x 128 x 51
26     support = torch.empty([0, K, 128, 51])
27     # initialize query tensor of dimension 0 x Q x 128 x 51
28     query = torch.empty([0, Q, 128, 51])
29     # random sample a reader
30     reader = random.sample(features, 1)[0]
31     words = []
32     # scan the torch tensor saved in each reader folder
33     for word in os.scandir(reader):
34         # create a list containing the path of the words
35         words.append(word.path)
36     # random sample C paths of the words of a reader
37     words = random.sample(words, C)
38     # randomize the instances of each word
39     for word in words:
40         # load the tensor containing the spectrograms of the instances of
41         # one word
42         spectrogram_buf = torch.load(word)
43         # get the spectrogram tensor shape
44         x_dim, y_dim, z_dim = spectrogram_buf.shape
45         # get the number of instances
46         instances_number = (spectrogram_buf.shape)[0]
47         # random sample K + Q indices
48         index = random.sample(list(torch.arange(instances_number)), K + Q)
49         # initialize the spectrogram tensor
50         spectrogram = torch.empty([0, 128, 51])
51         for i in index:
52             # concatenate spectrogram_buf with spectrogram to get a new
53             # tensor
54             # of random sampled instances of the word
55             spectrogram = torch.cat((spectrogram, (spectrogram_buf[i, :, :])
56                                     .view(1, y_dim, z_dim)), axis = 0)
57         # concatenate the first K spectrograms with the support set
58         support = torch.cat((support, (spectrogram[:K]).view(1, K, y_dim,
59                                                                z_dim)), axis = 0)
60         # concatenate the last Q spectrograms with the query set
61         query = torch.cat((query, (spectrogram[K:K+Q]).view(1, Q, y_dim,

```

```

55         z_dim)), axis = 0)
    return query, support

```

#### Codice 14: batch\_sample

Una volta ottenute, le feature del support set e query set vengono date in ingresso alla funzione `loss`. Queste ultime vengono messe in fila e concatenate per poter essere passate al modello che calcolerà gli embedding per ogni istanza. Gli elementi del support set che fanno parte della stessa classe andranno a costituire i prototipi tramite una media dei loro valori.

Il parametro `target_inds` viene costruito ripetendo l'indice di ogni classe per il numero di query e sarà utilizzato per poter ricordare a che classe appartiene ogni query.

Per ogni elemento del query set vengono calcolate le distanze rispetto ai prototipi di ogni classe tramite la funzione `euclidean_dist` che rappresenta la distanza euclidea. Per ogni query viene poi usata la funzione di attivazione `log_softmax` fra tutte le sue distanze. La funzione loss da minimizzare è costituita dalla media dei `log_softmax` della classe corrispondente alla query presi con segno negativo. Infatti, nel caso ideale in cui la distanza delle query della stessa classe dal prototipo è 0, la media dei softmax delle distanze dal prototipo assegnato sarà nulla. La accuracy invece è determinata dal numero dei casi in cui il prototipo a distanza minima da una query (o il massimo del softmax) corrisponde con il prototipo della classe associata alla query.

```

1  import torch
2  import torch.nn.functional as F
3  from torch.autograd import Variable
4
5  def euclidean_dist(x, y):
6      """
7          euclidean_dist computes the euclidean distance from two arrays x and y
8
9          Parameters:
10         x (torch.FloatTensor): query array
11         y (torch.FloatTensor): prototype array
12
13         Returns:
14         torch.pow(x - y, 2).sum(2) (double): the euclidean distance from x and y
15         """
16         # x: N x D
17         # y: M x D
18         n = x.size(0)
19         m = y.size(0)
20         d = x.size(1)
21         assert d == y.size(1)
22
23         x = x.unsqueeze(1).expand(n, m, d)
24         y = y.unsqueeze(0).expand(n, m, d)
25
26         return torch.pow(x - y, 2).sum(2)
27
28 def loss(xs, xq, model):
29     """

```

```

30     loss returns the loss and accuracy value. It calculates p_y, the loss
31     softmax over distances to the prototypes in the embedding space. We need
32     to
33     minimize the negative log-probability of p_y to proceed the learning
34     process.
35
36     Parameters:
37     xs (torch.FloatTensor): support set
38     xq (torch.FloatTensor): query set
39     model (torch.nn.Module): neural network model
40
41     Returns:
42     loss_val (double): loss value
43     acc_val (double): accuracy value
44     """
45     # xs = Variable()
46     n_class = xs.size(0)
47     assert xq.size(0) == n_class
48     n_support = xs.size(1)
49     n_query = xq.size(1)
50
51     target_inds = torch.arange(0, n_class).view(n_class, 1, 1).expand(
52         n_class, n_query, 1).long()
53     #target_inds = Variable(target_inds, requires_grad=False)
54
55     if torch.cuda.is_available():
56         target_inds = target_inds.to(device='cuda')
57
58     x = torch.cat([xs.view(n_class * n_support, *xs.size()[2:]),
59                   xq.view(n_class * n_query, *xq.size()[2:])], 0)
60
61     embeddings = model(x)
62
63     embeddings_dim = embeddings.size(-1)
64
65     prototypes = embeddings[:n_class*n_support].view(n_class, n_support,
66                                                         embeddings_dim).mean(1)
67
68     queries = embeddings[n_class*n_support:]
69
70     dists = euclidean_dist(queries, prototypes)
71
72     log_p_y = F.log_softmax(-dists, dim=1).view(n_class, n_query, -1)
73
74     loss_val = -log_p_y.gather(2, target_inds).squeeze().view(-1).mean()
75
76     _, y_hat = log_p_y.max(2)
77     acc_val = torch.eq(y_hat, target_inds.squeeze()).float().mean()
78
79     return loss_val, acc_val

```

Codice 15: protonet\_loss.py

Con `loss_out.backward()` viene utilizzata la loss per la retropropagazione che aggiorna i parametri della rete.

## 8.2 Prototypical validation

Ogni 5000 episodi del training vengono effettuati 1000 episodi di validation. Come nel training vengono ricavati support set e query set ma in questo caso dai lettori di validation. Per questi vengono calcolati con la funzione `loss` allo stesso modo `loss` e `accuracy` e vengono salvati. In questo caso però i parametri del modello non vengono aggiornati. Questo processo è necessario per verificare l'effettività del modello su ingressi mai visti in fase di training. Al termine dei 1000 episodi di validation, se la media dell'accuracy è migliore di quella calcolata nel batch precedente il modello viene salvato e sovrascritto al precedente, altrimenti viene ignorato. In questo modo si aggira il problema dell'overfitting fungendo da pseudo early stopping.

## 8.3 Prototypical test

```
1  import torch
2  import os
3  import random
4  import numpy as np
5  from protonet import *
6  from utils import *
7  from protonet_loss import *
8  from tqdm import tqdm
9  import sklearn.metrics
10
11 def test_predictions(model, negative_set, positive_set, query_set, n, p):
12     n_class = 2
13     n_query = query_set.size(0)
14
15     xs = torch.cat((positive_set, negative_set), 0)
16     x = torch.cat((xs, query_set), 0)
17
18     embeddings = model(x)
19     embeddings_dim = embeddings.size(-1)
20
21     positive_embeddings = embeddings[:p].view(1, p, embeddings_dim).mean(1)
22     negative_embeddings = embeddings[p:p+n].view(1, n, embeddings_dim).mean(1)
23     pos_neg_embeddings = torch.cat((positive_embeddings,
24                                     negative_embeddings), 0)
25     query_embeddings = embeddings[p+n:]
26     dists = euclidean_dist(query_embeddings, pos_neg_embeddings)
27
28     target_inds = torch.arange(n_class-1, -1, step = -1).view(n_class, 1).
29         expand(n_class, int(n_query/2)).long()
30
31     p_y = F.softmax(-dists, dim = 1).view(n_class, int(n_query/2), -1)
32
33     return p_y[:, :, 0].view(-1).detach(), target_inds.reshape(1, -1).squeeze()
34
35 def get_negative_positive_query_set(p, n, i, audio):
36     # initialize support tensor of dimension p x 128 x 51
37     positive_set = torch.empty([0, 128, 51])
```

```

36 negative_set = torch.empty([0, 128, 51])
37 # initialize query tensor of dimension n x 128 x 51
38 query_set = torch.empty([0, 128, 51])
39
40 words = []
41 for word in os.scandir(audio.path):
42     words.append(word.path)
43
44 pos_word = words[i]
45
46 spectrograms = torch.load(pos_word)
47 index = np.arange(spectrograms.shape[0])
48 pos_index = random.sample(list(index), p)
49 for i in pos_index:
50     pos = spectrograms[i, :, :]
51     positive_set = torch.cat((positive_set, pos.view(1, 128, 51)), axis
52                             = 0)
53 for i in index:
54     if i not in pos_index:
55         query = spectrograms[i, :, :]
56         query_set = torch.cat((query_set, query.view(1, 128, 51)), axis
57                             = 0)
58
59 query_label = [1]*query_set.shape[0]
60 query_label += [0]*positive_set.shape[0]
61
62 words.remove(pos_word)
63
64 for i in range(n):
65     neg = random.sample(words, 1)
66     spectrograms = torch.load(neg[0])
67     index = np.arange(spectrograms.shape[0])
68     neg_index = random.sample(list(index), 1)
69     neg = spectrograms[neg_index, :, :]
70     negative_set = torch.cat((negative_set, neg.view(1, 128, 51)), axis
71                             = 0)
72
73 for i in range(query_set.shape[0]):
74     query_sample = random.sample(words, 1)
75     spectrograms = torch.load(query_sample[0])
76     index = np.arange(spectrograms.shape[0])
77     query_index = random.sample(list(index), 1)
78     query = spectrograms[query_index, :, :]
79     query_set = torch.cat((query_set, query.view(1, 128, 51)), axis = 0)
80
81 return negative_set, positive_set, query_set
82
83 def main():
84     p = 5
85     n = 10
86
87     C = 2
88     K = 1
89
90     model = Protonet()
91     optim = torch.optim.Adam(model.parameters(), lr = 0.001)
92
93     if torch.cuda.is_available():
94         checkpoint = torch.load("Models/Prototypical/prototypical_model_C{
95             _K}.pt".format(C, K), map_location=torch.device('cuda'))
96     else:

```

```

93     checkpoint = torch.load("Models/Prototypical/prototypical_model_C{
        _K{}.pt".format(C, K), map_location=torch.device('cpu'))
94     model.load_state_dict(checkpoint['model_state_dict'])
95     optim.load_state_dict(checkpoint['optimizer_state_dict'])
96
97
98     model.eval()
99
100     if torch.cuda.is_available():
101         model.to(device='cuda')
102
103     auc_list = []
104     for audio in tqdm(os.listdir("Test_features/"), desc = "Test features"):
105         y_pred = []
106         y_true = []
107         # getting the number of target keywords in each audio
108         target_keywords_number = len([name for name in os.listdir(audio) if
            os.path.isfile(os.path.join(audio, name))])
109
110         for i in range(target_keywords_number):
111             for j in range(10):
112                 negative_set, positive_set, query_set =
                    get_negative_positive_query_set(p, n, i, audio)
113
114                 y_pred_tmp, y_true_tmp = test_predictions(model,
                    negative_set, positive_set, query_set, n, p)
115                 y_pred_tmp = y_pred_tmp.cpu().tolist()
116                 y_true_tmp = y_true_tmp.cpu().tolist()
117
118                 y_pred.extend(y_pred_tmp)
119                 y_true.extend(y_true_tmp)
120
121             precision, recall, thresholds = sklearn.metrics.
                precision_recall_curve(y_true, y_pred)
122             auc_tmp = sklearn.metrics.auc(recall, precision)
123             auc_list.append(auc_tmp)
124
125         auc = np.mean(auc_list)
126         print("Area under precision recall curve: {}".format(auc))
127         auc_std_dev = np.std(auc_list)
128         print("Standard deviation area under precision recall curve: {}".format(
            auc_std_dev))
129
130 if __name__ == "__main__":
131     main()

```

Codice 16: protonet\_test.py

Nella fase di test, seguendo l'articolo di riferimento, l'oggetto di interesse non sono i lettori come nel caso di training e validation. Vengono infatti presi in considerazione i singoli audio. Da questi sarà necessario identificare un gruppo di istanze di una parola (il positive\_set) e, campionando nell'audio, si potrà verificare se la rete è in grado di riconoscere la parola designata.

Per ogni audio quindi viene ricavato il numero di parole con spettrogramma (in base al contenuto di Test\_features). Per ognuna di esse viene ricavato un positive set e un negative set con i quali è possibile verificare la rete. Questo processo viene ripetuto 10 volte come in [3], in modo da generalizzare il



più possibile il test. Infatti, il positive set è ricavato campionando casualmente  $p$  istanze della parola che si sta analizzando, mentre il negative set è ottenuto campionando  $n$  istanze fra tutte le altre parole dello stesso audio. Per fare questo viene usata la funzione `get_negative_positive_query_set`. Tramite un indice che indica le istanze della parola "positiva" vengono campionati  $p$  spettrogrammi che vanno a costituire il positive set. Le restanti istanze della stessa parola vengono inserite invece nel query set come esempio di spettrogramma che la rete dovrebbe riconoscere. Tra l'elenco delle parole viene quindi rimossa la parola positiva con `words.remove(pos_word)`. Usando le restanti vengono ricavate  $n$  esempi di negative set campionando a caso una delle parole e una delle istanze di essa. Allo stesso modo viene formata la seconda metà del query set che rappresenta gli esempi negativi. Il numero di query negative viene preso uguale a quello delle positive.

A questo punto, i tre set e il modello sono parametri della funzione `test_predictions`. Allo stesso modo di training e validation vengono calcolati gli embedding per ogni istanza e i prototipi delle due classi: positive set e negative set. Vengono calcolate le distanze che sono passate con segno negativo alla funzione `log_softmax`. Tra i risultati viene selezionato l'elemento 0 della terza dimensione che rappresenta la probabilità che la query appartenga alla classe positiva. Queste predizioni sono contenute nel vettore `y_pred`, mentre in `y_true` sono presenti le label reali di ogni query.

La funzione `precision_recall_curve` utilizza `y_pred` e `y_true` per calcolare precision e recall. Infine, `sklearn.metrics.auc` calcola la AUPRC. Questo calcolo avviene al termine delle operazioni per ogni audio. Una volta terminati gli audio viene calcolata media e varianza degli AUPRC.

## 9 Codice Relation network

```

1  import torch
2  import torch.nn as nn
3  import math
4  import torch.nn.functional as F
5
6  class CNNEncoder(nn.Module):
7      """
8      CNNEncoder is the embedding module. The architecture consists of 4
9      convolutional block contains a
10     64-filter 3 X 3 convolution, a batch normalisation and a ReLU
11     nonlinearity layer respectively.
12     The first 3 blocks also contain a 2 X 2 max-pooling layer while the last
13     two do not. We do so
14     because we need the output feature maps for further convolutional layers
15     in the relation module
16     """
17     def __init__(self):
18         super(CNNEncoder, self).__init__()

```

```

15     self.layer1 = nn.Sequential(
16         nn.Conv2d(1,64,kernel_size=3,padding=0),
17         nn.BatchNorm2d(64, momentum=1, affine=True),
18         nn.ReLU(),
19         nn.MaxPool2d(2))
20     self.layer2 = nn.Sequential(
21         nn.Conv2d(64,64,kernel_size=3,padding=0),
22         nn.BatchNorm2d(64, momentum=1, affine=True),
23         nn.ReLU(),
24         nn.MaxPool2d(2))
25     self.layer3 = nn.Sequential(
26         nn.Conv2d(64,64,kernel_size=3,padding=1),
27         nn.BatchNorm2d(64, momentum=1, affine=True),
28         nn.ReLU(),
29         nn.MaxPool2d(2))
30     self.layer4 = nn.Sequential(
31         nn.Conv2d(64,64,kernel_size=3,padding=1),
32         nn.BatchNorm2d(64, momentum=1, affine=True),
33         nn.ReLU())
34     #nn.MaxPool2d(2))
35
36     def forward(self,x):
37         out = self.layer1(x)
38         out = self.layer2(out)
39         out = self.layer3(out)
40         out = self.layer4(out)
41         #out = out.view(out.size(0),-1)
42         return out # 64
43
44     class RelationNetwork(nn.Module):
45         """
46         The RelationNetwork is the relation module. It consists of two
47         convolutional blocks and
48         two fully-connected layers. Each of convolutional block is a 3 X 3
49         convolution with 64 filters
50         followed by batch normalisation, ReLU non-linearity and 2 X 2 max-
51         pooling.
52         The two fully-connected layers are 8 and 1 dimensional, respectively.
53         All fully-connected layers are
54         ReLU except the output layer is Sigmoid in order to generate relation
55         scores in a reasonable range
56         for all versions of our network architecture.
57         """
58         def __init__(self,input_size,hidden_size):
59             super(RelationNetwork, self).__init__()
60             self.layer1 = nn.Sequential(
61                 nn.Conv2d(128,64,kernel_size=3,padding=1),
62                 nn.BatchNorm2d(64, momentum=1, affine=True),
63                 nn.ReLU(),
64                 nn.MaxPool2d(2))
65             self.layer2 = nn.Sequential(
66                 nn.Conv2d(64,64,kernel_size=3,padding=1),
67                 nn.BatchNorm2d(64, momentum=1, affine=True),
68                 nn.ReLU(),
69                 nn.MaxPool2d(2))
70             self.fc1 = nn.Linear(input_size, hidden_size)
71             self.fc2 = nn.Linear(hidden_size, 1)
72
73         def forward(self,x):
74             out = self.layer1(x) # (CLASS_NUM * BATCH_NUM_PER_CLASS * 5) X
75                                # FEATURE_DIM X 2 X 2

```

```

70     out = self.layer2(out) # (CLASS_NUM * BATCH_NUM_PER_CLASS * 5) X
    FEATURE_DIM X 1 X 1
71     out = out.view(out.size(0), -1) # (CLASS_NUM * BATCH_NUM_PER_CLASS
    * 5) X FEATURE_DIM
72     out = F.relu(self.fc1(out)) # (CLASS_NUM * BATCH_NUM_PER_CLASS
    * 5) X RELATION_DIM
73     #out = F.sigmoid(self.fc2(out)) # deprecated
74     out = torch.sigmoid(self.fc2(out)) # (CLASS_NUM *
    BATCH_NUM_PER_CLASS * 5) X 1
75     return out
76
77 def weights_init(m):
78     classname = m.__class__.__name__
79     if classname.find('Conv') != -1:
80         n = m.kernel_size[0] * m.kernel_size[1] * m.out_channels
81         m.weight.data.normal_(0, math.sqrt(2. / n))
82         if m.bias is not None:
83             m.bias.data.zero_()
84     elif classname.find('BatchNorm') != -1:
85         m.weight.data.fill_(1)
86         m.bias.data.zero_()
87     elif classname.find('Linear') != -1:
88         n = m.weight.size(1)
89         m.weight.data.normal_(0, 0.01)
90         m.bias.data = torch.ones(m.bias.data.size())

```

Codice 17: relation\_network.py

Le reti neurali necessarie per la relation network sono effettivamente due.

La prima, chiamata `CNNEncoder` ha lo stesso scopo della rete nella prototypical, ovvero a partire dalle feature in ingresso produce degli embedding monodimensionali che possono essere confrontati. Anche in questo caso i layer sono 4 e sono costituiti da:

- `nn.Conv2d()`: Convoluzione bidimensionale con un kernel 3x3 i cui parametri vengono aggiornati ad ogni backward. Viene effettuato un padding di zeri ai bordi dell'ingresso.
- `nn.BatchNorm2d()`: La batch normalization è un metodo utilizzato per rendere le reti neurali artificiali più veloci e stabili attraverso la normalizzazione degli input dei livelli con re-centering and re-scaling.
- `nn.ReLU()`: il rettificatore è una funzione di attivazione definita come la parte positiva del suo argomento.  $f(x) = \max(0, x)$
- `nn.MaxPool2d(2)`: Il max-pooling è un metodo per ridurre la dimensione di un'immagine, suddividendola in blocchi e tenendo solo quello col valore più alto.

Seguendo le indicazioni in [3] i primi due blocchi hanno padding pari a 0 mentre negli ultimi due padding=1. Inoltre, per soddisfare le dimensioni necessarie in ingresso alla seconda rete neurale, il Max Pooling è presente

solo nei primi 3 layer. Questo concetto sarà approfondito nel capitolo di training.

La seconda rete è detta `RelationNetwork` e ha lo scopo di confrontare le concatenazioni di embedding per predire o meno la loro somiglianza. Essa è costituita da 2 layer di `nn.Conv2d()`, `nn.BatchNorm2d()`, `nn.ReLU()` e `nn.MaxPool2d(2)` al termine dei quali viene eseguito un flattening che riduce l'uscita a un vettore. In seguito vengono applicati una ulteriore relu e una sigmoide.

## 9.1 Relation training

```
1  import torch
2  import torch.nn as nn
3  from torch.autograd import Variable
4  import torch.nn.functional as F
5  from tqdm import trange, tqdm
6  import numpy as np
7  import scipy
8  from scipy import io
9
10 # Hyper Parameters
11 FEATURE_DIM = 64
12 RELATION_DIM = 8
13 CLASS_NUM = 5
14 SAMPLE_NUM_PER_CLASS = 1
15 BATCH_NUM_PER_CLASS = 16
16 EPISODE = 60000
17 TEST_EPISODE = 1000
18 LEARNING_RATE = 0.001
19 GPU = 0
20 HIDDEN_UNIT = 10
21
22 if torch.cuda.is_available():
23     device = torch.device("cuda")
24     print("Device: {}".format(device))
25     print("Device name: {}".format(torch.cuda.get_device_properties(device).
26                                     name))
27 else:
28     device = torch.device("cpu")
29
30 # Step 1: init data folders
31 print("init data folders")
32 # init character folders for dataset construction
33 training_readers, validation_readers = get_training_validation_readers("/
34 content/drive/MyDrive/Few-Shot-Sound-Event-Detection/
35 Training_validation_features/", CLASS_NUM)
36
37 # Step 2: init neural networks
38 print("init neural networks")
39
40 feature_encoder = CNNEncoder()
41 relation_network = RelationNetwork(FEATURE_DIM, RELATION_DIM)
42
43 feature_encoder.apply(weights_init)
44 relation_network.apply(weights_init)
```

```

43 if torch.cuda.is_available():
44     feature_encoder.to(device='cuda')
45     relation_network.to(device='cuda')
46
47 feature_encoder_optim = torch.optim.Adam(feature_encoder.parameters(), lr =
    LEARNING_RATE)
48 relation_network_optim = torch.optim.Adam(relation_network.parameters(), lr
    = LEARNING_RATE)
49
50 # Step 3: build graph
51 print("Training...")
52
53 train_loss = []
54 validation_loss = []
55
56 last_accuracy = 0.0
57
58 for episode in tqdm(range(EPISODE), desc = "training episode", position=0):
59
60     # sample datas
61     batches, samples = batch_sample(training_readers, CLASS_NUM,
        SAMPLE_NUM_PER_CLASS, BATCH_NUM_PER_CLASS) # samples: C X K X 128 X
        51, batches: C X Q X 128 X 51
62
63     samples = samples.view(CLASS_NUM * SAMPLE_NUM_PER_CLASS, 1, *samples.
        size()[2:]) # (C X K) X 1 X 51 X 51
64     batches = batches.view(CLASS_NUM * BATCH_NUM_PER_CLASS, 1, *batches.size
        ()[2:]) # (C X Q) X 1 X 51 X 51
65
66     if torch.cuda.is_available():
67         samples = samples.to(device='cuda')
68         batches = batches.to(device='cuda')
69
70     # calculate features
71     sample_features = feature_encoder(Variable(samples)) # (CLASS_NUM *
        SAMPLE_NUM_PER_CLASS) X FEATURE_DIM X 5 X 5
72
73     # resize the images from 15 X 5 to 5 X 5 to get square images
74     # interpolate down samples the input to the given size
75     sample_features = F.interpolate(sample_features, size = 5)
76     sample_features = sample_features.view(CLASS_NUM, SAMPLE_NUM_PER_CLASS,
        FEATURE_DIM, 5, 5) # CLASS_NUM X SAMPLE_NUM_PER_CLASS X FEATURE_DIM
        X 5 X 5
77     sample_features = torch.sum(sample_features,1).squeeze(1) # CLASS_NUM
        X FEATURE_DIM X 5 X 5
78
79     batch_features = feature_encoder(Variable(batches)) # (CLASS_NUM *
        BATCH_NUM_PER_CLASS) X FEATURE_DIM X 5 X 5
80     batch_features = F.interpolate(batch_features, size = 5)
81
82     # calculate relations
83     # each batch sample link to every samples to calculate relations
84     sample_features_ext = sample_features.unsqueeze(0).repeat(CLASS_NUM *
        BATCH_NUM_PER_CLASS, 1, 1, 1, 1) # (CLASS_NUM * BATCH_NUM_PER_CLASS)
        X 5 X FEATURE_DIM X 5 X 5
85     batch_features_ext = batch_features.unsqueeze(0).repeat(CLASS_NUM, 1, 1,
        1, 1) # 5 X (CLASS_NUM * BATCH_NUM_PER_CLASS) X FEATURE_DIM X 5 X
        5
86     batch_features_ext = torch.transpose(batch_features_ext, 0, 1) # (
        CLASS_NUM * BATCH_NUM_PER_CLASS) X 5 X FEATURE_DIM X 5 X 5
87

```

```

88     relation_pairs = torch.cat((sample_features_ext, batch_features_ext), 2).
        view(-1, FEATURE_DIM*2, 5, 5) # (CLASS_NUM * BATCH_NUM_PER_CLASS *
        5) X (FEATURE_DIM * 2) X 5 X 5
89     relations = relation_network(relation_pairs).view(-1, CLASS_NUM) # (
        CLASS_NUM * BATCH_NUM_PER_CLASS) X CLASS_NUM
90
91     mse = nn.MSELoss()
92
93     one_hot_labels = Variable(torch.zeros(BATCH_NUM_PER_CLASS*CLASS_NUM,
        CLASS_NUM))
94
95     for i in range(CLASS_NUM):
96         for j in range(BATCH_NUM_PER_CLASS):
97             one_hot_labels[BATCH_NUM_PER_CLASS*i+j, i] = 1
98
99     if torch.cuda.is_available():
100         mse = mse.to(device='cuda')
101         one_hot_labels = one_hot_labels.to(device='cuda')
102
103     loss = mse(relations, one_hot_labels)
104
105     # training
106
107     feature_encoder.zero_grad()
108     relation_network.zero_grad()
109
110     loss.backward()
111
112     torch.nn.utils.clip_grad_norm_(feature_encoder.parameters(), 0.5)
113     torch.nn.utils.clip_grad_norm_(relation_network.parameters(), 0.5)
114
115     feature_encoder_optim.step()
116     relation_network_optim.step()
117
118     train_loss.append(loss.item())
119
120     if (episode+1)%5000 == 0:
121         total_rewards = 0
122         #for i in tqdm(range(TEST_EPISODE), desc = "validation episode",
            position = 1, leave = False):
123             for validation_episode in range(TEST_EPISODE):
124                 # sample datas
125                 batches, samples = batch_sample(validation_readers, CLASS_NUM,
                    SAMPLE_NUM_PER_CLASS, BATCH_NUM_PER_CLASS) # samples: C X K X
                    128 X 51, batches: C X Q X 128 X 51
126
127                 samples = samples.view(CLASS_NUM * SAMPLE_NUM_PER_CLASS, 1, *samples
                    .size()[2:]) # (C X K) X 1 X 51 X 51
128                 batches = batches.view(CLASS_NUM * BATCH_NUM_PER_CLASS, 1, *batches.
                    size()[2:]) # (C X Q) X 1 X 51 X 51
129
130                 if torch.cuda.is_available():
131                     samples = samples.to(device)
132                     batches = batches.to(device)
133
134                 # calculate features
135                 sample_features = feature_encoder(Variable(samples)) # (CLASS_NUM *
                    SAMPLE_NUM_PER_CLASS) X FEATURE_DIM X 5 X 5
136
137                 # resize the images from 15 X 5 to 5 X 5 to get square images
138                 # interpolate down samples the input to the given size
139                 sample_features = F.interpolate(sample_features, size = 5)

```

```

140     sample_features = sample_features.view(CLASS_NUM,
        SAMPLE_NUM_PER_CLASS, FEATURE_DIM, 5, 5) # CLASS_NUM X
        SAMPLE_NUM_PER_CLASS X FEATURE_DIM X 5 X 5
141     sample_features = torch.sum(sample_features,1).squeeze(1) #
        CLASS_NUM X FEATURE_DIM X 5 X 5
142
143     batch_features = feature_encoder(Variable(batches)) # (CLASS_NUM *
        BATCH_NUM_PER_CLASS) X FEATURE_DIM X 5 X 5
144     batch_features = F.interpolate(batch_features, size = 5)
145
146     # calculate relations
147     # each batch sample link to every samples to calculate relations
148     sample_features_ext = sample_features.unsqueeze(0).repeat(CLASS_NUM
        * BATCH_NUM_PER_CLASS, 1, 1, 1, 1) # (CLASS_NUM *
        BATCH_NUM_PER_CLASS) X 5 X FEATURE_DIM X 5 X 5
149     batch_features_ext = batch_features.unsqueeze(0).repeat(CLASS_NUM,
        1, 1, 1, 1) # 5 X (CLASS_NUM * BATCH_NUM_PER_CLASS) X
        FEATURE_DIM X 5 X 5
150     batch_features_ext = torch.transpose(batch_features_ext, 0, 1) # (
        CLASS_NUM * BATCH_NUM_PER_CLASS) X 5 X FEATURE_DIM X 5 X 5
151
152     relation_pairs = torch.cat((sample_features_ext, batch_features_ext),
        2).view(-1, FEATURE_DIM*2, 5, 5) # (CLASS_NUM *
        BATCH_NUM_PER_CLASS * 5) X (FEATURE_DIM * 2) X 5 X 5
153     relations = relation_network(relation_pairs).view(-1, CLASS_NUM) # (
        CLASS_NUM * BATCH_NUM_PER_CLASS) X CLASS_NUM
154
155     _, predict_labels = torch.max(relations.data, 1)
156
157     test_labels = torch.arange(CLASS_NUM).expand(BATCH_NUM_PER_CLASS,
        CLASS_NUM).transpose(1, 0).reshape(-1)
158
159     rewards = [1 if predict_labels[j]==test_labels[j] else 0 for j in
        range(CLASS_NUM*BATCH_NUM_PER_CLASS)]
160
161     total_rewards += np.sum(rewards)
162
163     valid_accuracy = total_rewards/1.0/CLASS_NUM/BATCH_NUM_PER_CLASS/
        TEST_EPISODE
164
165     print("\nTest accuracy: {}".format(valid_accuracy))
166
167     if valid_accuracy > last_accuracy:
168         torch.save({
169             'epoch': episode+1,
170             'feature_encoder_state_dict': feature_encoder.state_dict
                (),
171             'relation_network_state_dict' : relation_network.
                state_dict(),
172             'feature_encoder_optim_state_dict':
                feature_encoder_optim.state_dict(),
173             'relation_network_optim_state_dict':
                relation_network_optim.state_dict(),
174             'train_loss': train_loss,
175             'avg_loss_tr' : np.mean(train_loss),
176             'valid_acc' : valid_accuracy,
177             'avg_acc_val' : np.mean(valid_accuracy),
178             }, "/content/drive/MyDrive/Few-Shot-Sound-Event-
                Detection/Modelli-Relation-Network/relation_model_C
                {}_K{}.pt".format(CLASS_NUM, SAMPLE_NUM_PER_CLASS))
179     last_accuracy = valid_accuracy
180

```

```

181     scipy.io.savemat('/content/drive/MyDrive/Few-Shot-Sound-Event-
        Detection/Modelli-Relation-Network/relation_results_C{}_K{}.mat'
        .format(CLASS_NUM, SAMPLE_NUM_PER_CLASS), {'train_loss':
        train_loss, 'valid_accuracy': valid_accuracy})
182
183 print('Average train loss: {}'.format(np.mean(train_loss)))

```

Codice 18: relation\_training.py

Come nella rete precedente, il primo passo consiste nel campionare i lettori di training e validation con la funzione `get_training_validation_readers`. Le due reti `CNNEncoder` e `RelationNetwork` con i rispettivi pesi vengono inizializzate. Per ogni episodio viene poi campionato un support set e query set per un lettore designato. Le istanze complessive vengono poi passate alla prima rete per costruire gli embedding. Gli embedding del support set hanno ora dimensione  $C \times K \times 64 \times 15 \times 5$  mentre quelli del query set sono  $C \times Q \times 64 \times 15 \times 5$ .

Prima di essere passati alla seconda rete questi tensori necessitano di avere le ultime due dimensioni pari a 5. In questo modo, attraversando due volte lo strato di max pooling passeranno da  $5 \times 5$  a  $2 \times 2$  a  $1 \times 1$ . In seguito al flattening le ultime due dimensioni scompaiono e l'ingresso alla relu ha la dimensione corretta:  $C \times Q \times C \times 64$ . Le concatenazioni hanno dimensione  $C \times Q \times C \times 64 \times 5 \times 5$ , infatti ogni query ( $C \times Q$ ) va concetenata con il vettore che rappresenta ognuna delle classi ( $C$ ). Quest'ultimo vettore è ottenuto sommando elemento per elemento gli embedding delle istanze di ogni classe usando `torch.sum(sample_features, 1).squeeze(1)`. La rete decisionale restituisce quindi un vettore `relations`  $C \times Q \times C \times 1$  che viene poi suddiviso in una matrice  $C \times Q \times C$  in cui in ogni riga sono presenti le probabilità che una data query appartenga alle varie classi. La matrice `one_hot_labels` ha la stessa forma di `relations` ma è costituito da zeri tranne nelle colonne in cui la classe corrisponde realmente alla query, in cui il valore è pari a 1. Questa rappresenta il risultato ideale che vogliamo in uscita dalla rete. Usando quindi la funzione `mse` con parametri `relations` e `one_hot_labels` otteniamo la loss che viene utilizzata per aggiornare i parametri delle due reti con `loss.backward()`.

## 9.2 Relation validation

Ogni 5000 episodi di training ne vengono effettuati 1000 di validation. Come nella prototypical network vengono utilizzati lettori di validation sconosciuti alla rete e, nel caso in cui il batch produca una accuracy migliore di quello precedente, il modello viene salvato. Per fare ciò viene utilizzato un vettore `reward` che conta il numero di volte in cui il valore massimo tra le predizioni della classe da associare a una query corrisponde con quello reale. L'accuracy



infatti equivale al numero di reward diviso il totale delle query, mediato nei 1000 episodi del batch di validation.

### 9.3 Relation test

```

1  import torch
2  import os
3  import random
4  import numpy as np
5  from relation_network import *
6  from utils import *
7  from protonet_loss import *
8  from tqdm import tqdm
9  import sklearn.metrics
10
11 def test_predictions(feature_encoder, relation_network, positive_set,
12                     negative_set, query_set, n, p):
13     n_class = 2
14     n_query = query_set.size(0)
15
16     FEATURE_DIM = 64
17
18     pos_embeddings = feature_encoder(Variable(positive_set)) # (CLASS_NUM *
19     SAMPLE_NUM_PER_CLASS) X FEATURE_DIM X 5 X 5
20
21     # resize the images from 15 X 5 to 5 X 5 to get square images
22     # interpolate down samples the input to the given size
23     pos_embeddings = F.interpolate(pos_embeddings, size = 5)
24     pos_embeddings = pos_embeddings.view(1, p, FEATURE_DIM, 5, 5) #
25     CLASS_NUM X SAMPLE_NUM_PER_CLASS X FEATURE_DIM X 5 X 5
26     pos_embeddings = torch.sum(pos_embeddings, 1).squeeze(1) # CLASS_NUM X
27     FEATURE_DIM X 5 X 5
28
29     neg_embeddings = feature_encoder(Variable(negative_set)) # (CLASS_NUM *
30     SAMPLE_NUM_PER_CLASS) X FEATURE_DIM X 5 X 5
31
32     # resize the images from 15 X 5 to 5 X 5 to get square images
33     # interpolate down samples the input to the given size
34     neg_embeddings = F.interpolate(neg_embeddings, size = 5)
35     neg_embeddings = neg_embeddings.view(1, n, FEATURE_DIM, 5, 5) #
36     CLASS_NUM X SAMPLE_NUM_PER_CLASS X FEATURE_DIM X 5 X 5
37     neg_embeddings = torch.sum(neg_embeddings, 1).squeeze(1) # CLASS_NUM X
38     FEATURE_DIM X 5 X 5
39
40     batch_features = feature_encoder(Variable(query_set)) # (CLASS_NUM *
41     BATCH_NUM_PER_CLASS) X FEATURE_DIM X 5 X 5
42     batch_features = F.interpolate(batch_features, size = 5)
43
44     pos_neg_embeddings = torch.cat((pos_embeddings, neg_embeddings), 0)
45
46     # calculate relations
47     # each batch sample link to every samples to calculate relations
48     pos_neg_embeddings_ext = pos_neg_embeddings.unsqueeze(0).repeat(int(
49         n_class * n_query/2), 1, 1, 1, 1) # (CLASS_NUM * BATCH_NUM_PER_CLASS
50         ) X 5 X 5 X FEATURE_DIM X 5 X 5
51
52     batch_features_ext = batch_features.unsqueeze(0).repeat(n_class, 1, 1,
53         1, 1) # 5 X (CLASS_NUM * BATCH_NUM_PER_CLASS) X FEATURE_DIM X 5 X 5

```

```

43     batch_features_ext = torch.transpose(batch_features_ext, 0, 1) # (
44         CLASS_NUM * BATCH_NUM_PER_CLASS) X CLASS_NUM X FEATURE_DIM X 5 X 5
45     relation_pairs = torch.cat((pos_neg_embeddings_ext, batch_features_ext),
46         2).view(-1, FEATURE_DIM*2, 5, 5) # (CLASS_NUM *
47         BATCH_NUM_PER_CLASS * CLASS_NUM) X (FEATURE_DIM * 2) X 5 X 5
48     relations = relation_network(relation_pairs).view(-1, n_class) # (
49         CLASS_NUM * BATCH_NUM_PER_CLASS) X CLASS_NUM
50     target_inds = torch.arange(n_class-1, -1, step = -1).view(n_class, 1).
51         expand(n_class, int(n_query/2)).long()
52     return relations[:,0].view(-1).detach(), target_inds.reshape(1, -1).
53         squeeze()
54
55 def get_negative_positive_query_set(p, n, i, audio):
56     # initialize support tensor of dimension p x 128 x 51
57     positive_set = torch.empty([0, 128, 51])
58     negative_set = torch.empty([0, 128, 51])
59     # initialize query tensor of dimension n x 128 x 51
60     query_set = torch.empty([0, 128, 51])
61
62     words = []
63     for word in os.scandir(audio.path):
64         words.append(word.path)
65
66     pos_word = words[i]
67
68     spectrograms = torch.load(pos_word)
69     index = np.arange(spectrograms.shape[0])
70     pos_index = random.sample(list(index), p)
71     for i in pos_index:
72         pos = spectrograms[i, :, :]
73         positive_set = torch.cat((positive_set, pos.view(1, 128, 51)), axis
74             = 0)
75     for i in index:
76         if i not in pos_index:
77             query = spectrograms[i, :, :]
78             query_set = torch.cat((query_set, query.view(1, 128, 51)), axis
79                 = 0)
80
81     query_label = [1]*query_set.shape[0]
82     query_label += [0]*query_set.shape[0]
83
84     words.remove(pos_word)
85
86     for i in range(n):
87         neg = random.sample(words, 1)
88         spectrograms = torch.load(neg[0])
89         index = np.arange(spectrograms.shape[0])
90         neg_index = random.sample(list(index), 1)
91         neg = spectrograms[neg_index, :, :]
92         negative_set = torch.cat((negative_set, neg.view(1, 128, 51)), axis
93             = 0)
94
95     for i in range(query_set.shape[0]):
96         query_sample = random.sample(words, 1)
97         spectrograms = torch.load(query_sample[0])
98         index = np.arange(spectrograms.shape[0])
99         query_index = random.sample(list(index), 1)
100         query = spectrograms[query_index, :, :]
101         query_set = torch.cat((query_set, query.view(1, 128, 51)), axis = 0)

```

```

96
97     return negative_set, positive_set, query_set
98
99 def main():
100     p = 5
101     n = 10
102
103     C = 2
104     K = 5
105
106     FEATURE_DIM = 64
107     RELATION_DIM = 8
108
109     feature_encoder = CNNEncoder()
110     relation_network = RelationNetwork(FEATURE_DIM, RELATION_DIM)
111
112     if torch.cuda.is_available():
113         checkpoint = torch.load("Models/Relation/relation_model_C{}_K{}.pt".
114                                 format(C, K), map_location=torch.device('cuda'))
115     else:
116         checkpoint = torch.load("Models/Relation/relation_model_C{}_K{}.pt".
117                                 format(C, K), map_location=torch.device('cpu'))
118     feature_encoder.load_state_dict(checkpoint['feature_encoder_state_dict'])
119     relation_network.load_state_dict(checkpoint['relation_network_state_dict'])
120
121     feature_encoder.eval()
122     relation_network.eval()
123
124     if torch.cuda.is_available():
125         feature_encoder.to(device='cuda')
126         relation_network.to(device='cuda')
127
128     auc_list = []
129     for audio in tqdm(os.listdir("Test_features/"), desc = "Test features"):
130         y_pred = []
131         y_true = []
132         # getting the number of target keywords in each audio
133         target_keywords_number = len([name for name in os.listdir(audio) if
134                                     os.path.isfile(os.path.join(audio, name))])
135
136         for i in range(target_keywords_number):
137             for j in range(1):
138                 negative_set, positive_set, query_set =
139                     get_negative_positive_query_set(p, n, i, audio)
140
141                 negative_set = negative_set.view(1 * n, 1, *negative_set.
142                                                     size()[1:])
143                 positive_set = positive_set.view(1 * p, 1, *positive_set.
144                                                     size()[1:])
145                 query_set = query_set.view(int(C * query_set.size()[0]/2),
146                                             1, *query_set.size()[1:]) # (C X Q) X 1 X 51 X 51
147
148                 y_pred_tmp, y_true_tmp = test_predictions(feature_encoder,
149                                                             relation_network, positive_set, negative_set, query_set,
150                                                             n, p)
151
152                 y_pred.extend(y_pred_tmp)
153                 y_true.extend(y_true_tmp)
154
155

```

```

147     precision, recall, thresholds = sklearn.metrics.
        precision_recall_curve(y_true, y_pred)
148     auc_tmp = sklearn.metrics.auc(recall, precision)
149     print("auc_tmp: {}".format(auc_tmp))
150     auc_list.append(auc_tmp)
151     """
152     prob_query_pos_iter.extend(prob_query_neg_iter)
153     prob_pos_iter = prob_query_pos_iter
154
155     target_inds_iter = np.ones(int(len(prob_pos_iter)/2))
156     target_inds_iter = np.append(target_inds_iter, np.zeros(int(len(
        prob_pos_iter)/2)))
157
158     precision, recall, thresholds = sklearn.metrics.precision_recall_curve(
        target_inds_iter, prob_pos_iter)
159     """
160     auc = np.mean(auc_list)
161     print("Area under precision recall curve: {}".format(auc))
162     auc_std_dev = np.std(auc_list)
163     print("Standard deviation area under precision recall curve: {}".format(
        auc_std_dev))
164
165     #average_precision = sklearn.metrics.average_precision_score(np.array(
        target_inds_iter), prob_pos_iter)
166     #print('Average precision: {}'.format(average_precision))
167
168 if __name__ == "__main__":
169     main()

```

Codice 19: relation\_test.py

Anche in questo il test ha come oggetto di analisi i singoli audio del dataset e non i lettori. Le fasi del test sono analoghe alla Prototypical network ma cambia la funzione che calcola le predizioni `test_predictions`. Come in precedenza, il positive set, il negative set e il query set sono passati in ingresso alla prima rete che ne calcola gli embedding. Ricordando la necessità di sottocampionare la penultima dimensione del tensore, positive e negative set vengono concatenati in quanto svolgono il ruolo delle classi con cui confrontare la query. Tutte le query vengono quindi concatenate con i vettori rappresentanti delle due classi producendo un numero di concatenazioni pari a il numero di query (ovvero il doppio delle istanze rimanenti nella classe positiva dopo la creazione del positive set) moltiplicato per 2.

Questo tensore viene poi passata alla rete che calcola le predizioni su quale delle classi (positive set e negative set) sia più simile alla query. In questo modo la rete produce una coppia di valori che indicano la probabilità con cui una query è associata ai due set. Di questi viene presa solo l'elemento 0 che indica l'affinità con il positive set. Utilizzando poi un corrispettivo valore che contiene il valore atteso reale è possibile calcolare precision, recall e AUPRC.

## Riferimenti bibliografici

- [1] Arne Köhn, Florian Stegen e Timo Baumann. «Mining the Spoken Wikipedia for Speech Data and Beyond». Inglese. In: *Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC 2016)* (23–28 mag. 2016). A cura di Nicoletta Calzolari (Conference Chair), Khalid Choukri, Thierry Declerck, Marko Grobelnik, Bente Maegaard, Joseph Mariani, Asuncion Moreno, Jan Odijk e Stelios Piperidis. Portorož, Slovenia: European Language Resources Association (ELRA). ISBN: 978-2-9517408-9-1.
- [2] Jake Snell, Kevin Swersky e Richard S. Zemel. *Prototypical Networks for Few-shot Learning*. 2017. arXiv: 1703.05175 [cs.LG].
- [3] Flood Sung, Yongxin Yang, Li Zhang, Tao Xiang, Philip H. S. Torr e Timothy M. Hospedales. «Learning to Compare: Relation Network for Few-Shot Learning». In: *CoRR* abs/1711.06025 (2017). arXiv: 1711.06025. URL: <http://arxiv.org/abs/1711.06025>.
- [4] Yu Wang, Justin Salamon, Nicholas J. Bryan e Juan Pablo Bello. *Few-Shot Sound Event Detection*. 2020, pp. 81–85. DOI: 10.1109/ICASSP40776.2020.9054708.